

ENGENHARIA DA COMPUTAÇÃO
UNIVERSIDADE FEDERAL DO MARANHÃO




APRESENTANDO


Elementos e Conceitos Básicos de Redes Neurais, Perceptron

**Juan Pablo Mondego
Diogo Brasil**

NEURÔNIO BIOLÓGICO




CONEXÃO SINÁPTICAS



NEURÔNIO ARTIFICIAL

Unidade de processamento que recebe entradas (x_i) com respectivos pesos (w_i) e calcula um somatório. Em seguida, aplica-se uma função de ativação para obter a saída do neurônio



FORMALIZAÇÃO MATEMÁTICA SIMPLES

Seja uma rede com camadas organizadas, onde cada neurônio i na camada l recebe entradas $x_j^{(l-1)}$ da camada anterior $l - 1$, ponderadas por pesos $w_{ij}^{(l)}$:

$$z_i^{(l)} = \sum_j w_{ij}^{(l)} x_j^{(l-1)} + b_i^{(l)}$$

Aqui:


- $z_i^{(l)}$ é o somatório ponderado no neurônio i da camada l .
- $w_{ij}^{(l)}$ é o peso da aresta do neurônio j da camada anterior para o neurônio i .
- $b_i^{(l)}$ é o viés (bias) do neurônio i .
- A saída do neurônio é a ativação não linear $x_i^{(l)} = \sigma(z_i^{(l)})$.




ARQUITETURA DE RNA

Feedforward: O fluxo de dados segue apenas de “esquerda para direita”, ou seja, da camada de entrada até a saída, sem loops

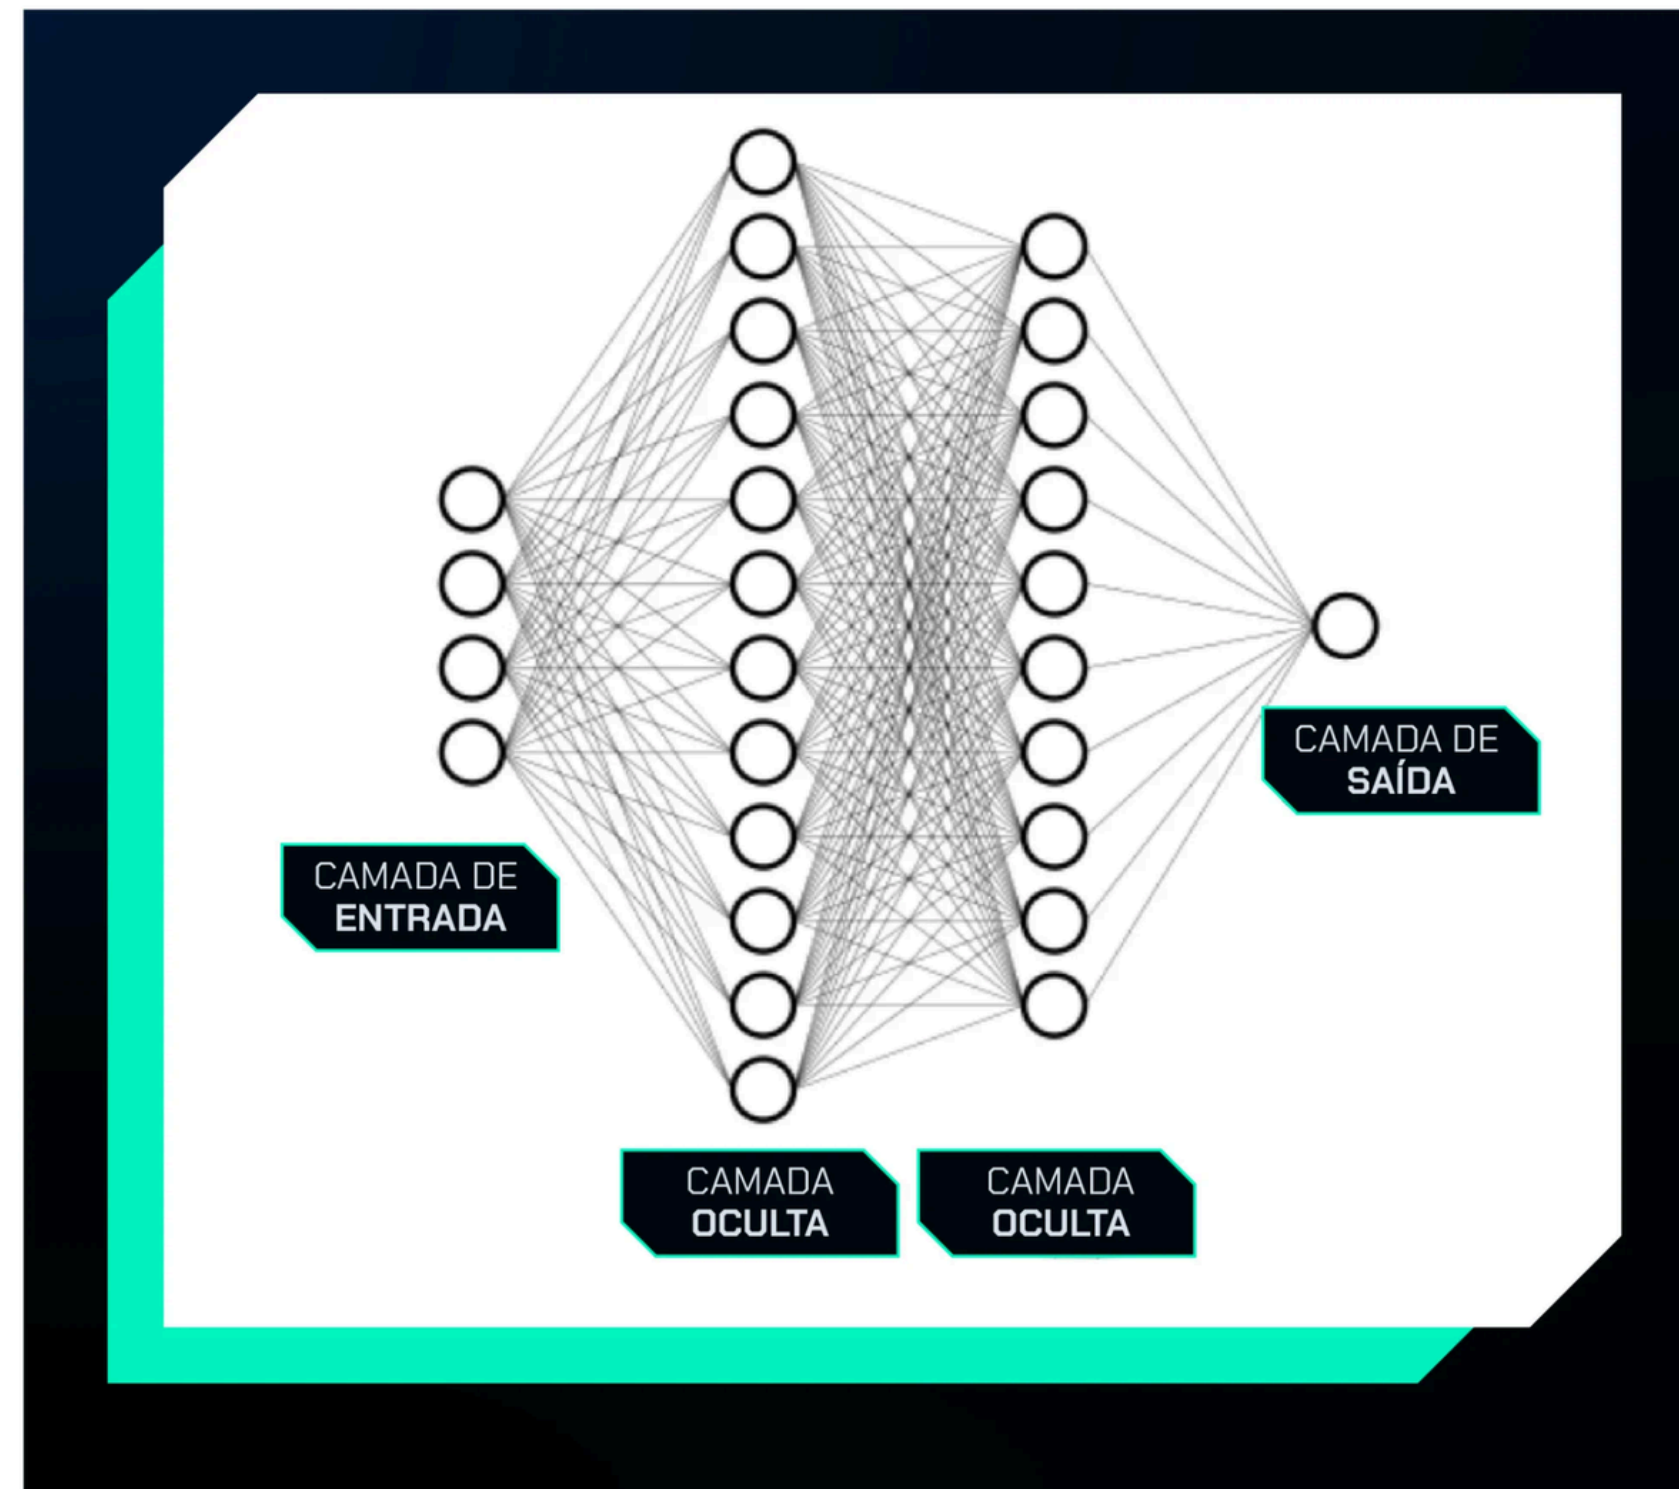
Recorrentes (RNN): Há realimentação dos neurônios, permitindo que a saída de camadas anteriores influencie os passos seguintes




REDES NEURAIS RECORRENTES (RNNS)



PERCEPTRON MULTICAMADAS (MLP)

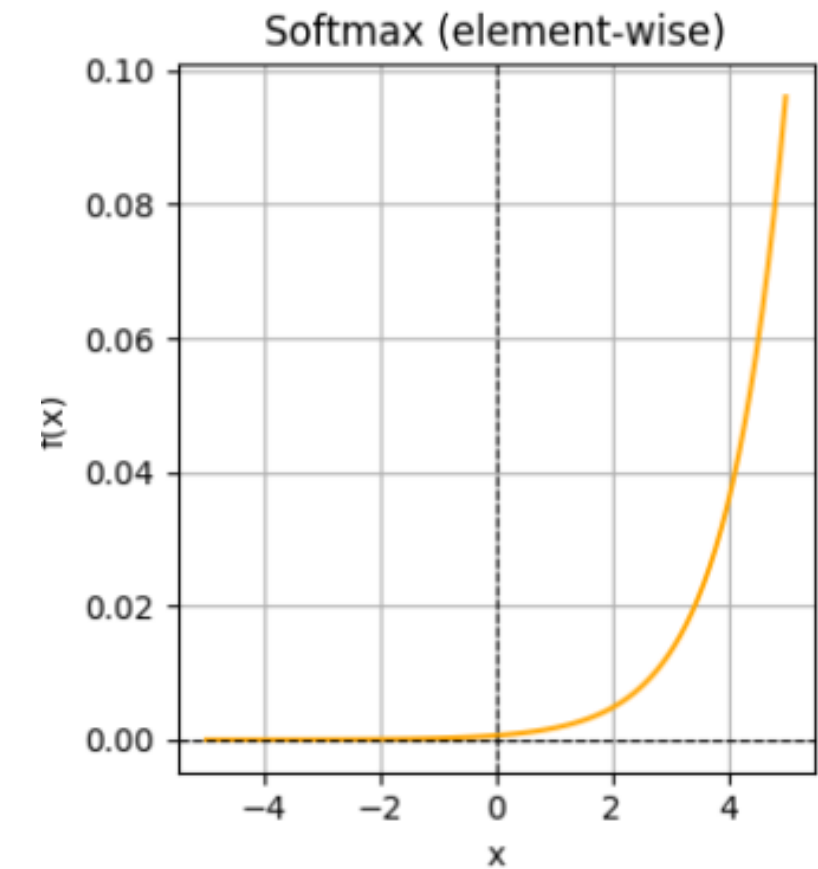





REDES NEURAIS CONVOLUCIONAIS (CNNs)



FUNÇÕES DE ATIVAÇÃO

- Sigmoid: $f(x) = \frac{1}{1+e^{-x}}$
- Tanh: $f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
- ReLU (Rectified Linear Unit): $f(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases}$
- Softmax: $f(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$



FUNÇÕES CUSTO

A função de custo mede o quão distante o modelo está do objetivo.

- **Erro Quadrático Médio (MSE)**

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Utilizada em problemas de regressão (ativação linear na saída).

- **Entropia Cruzada Binária (Binary Cross-Entropy – BCE):**

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

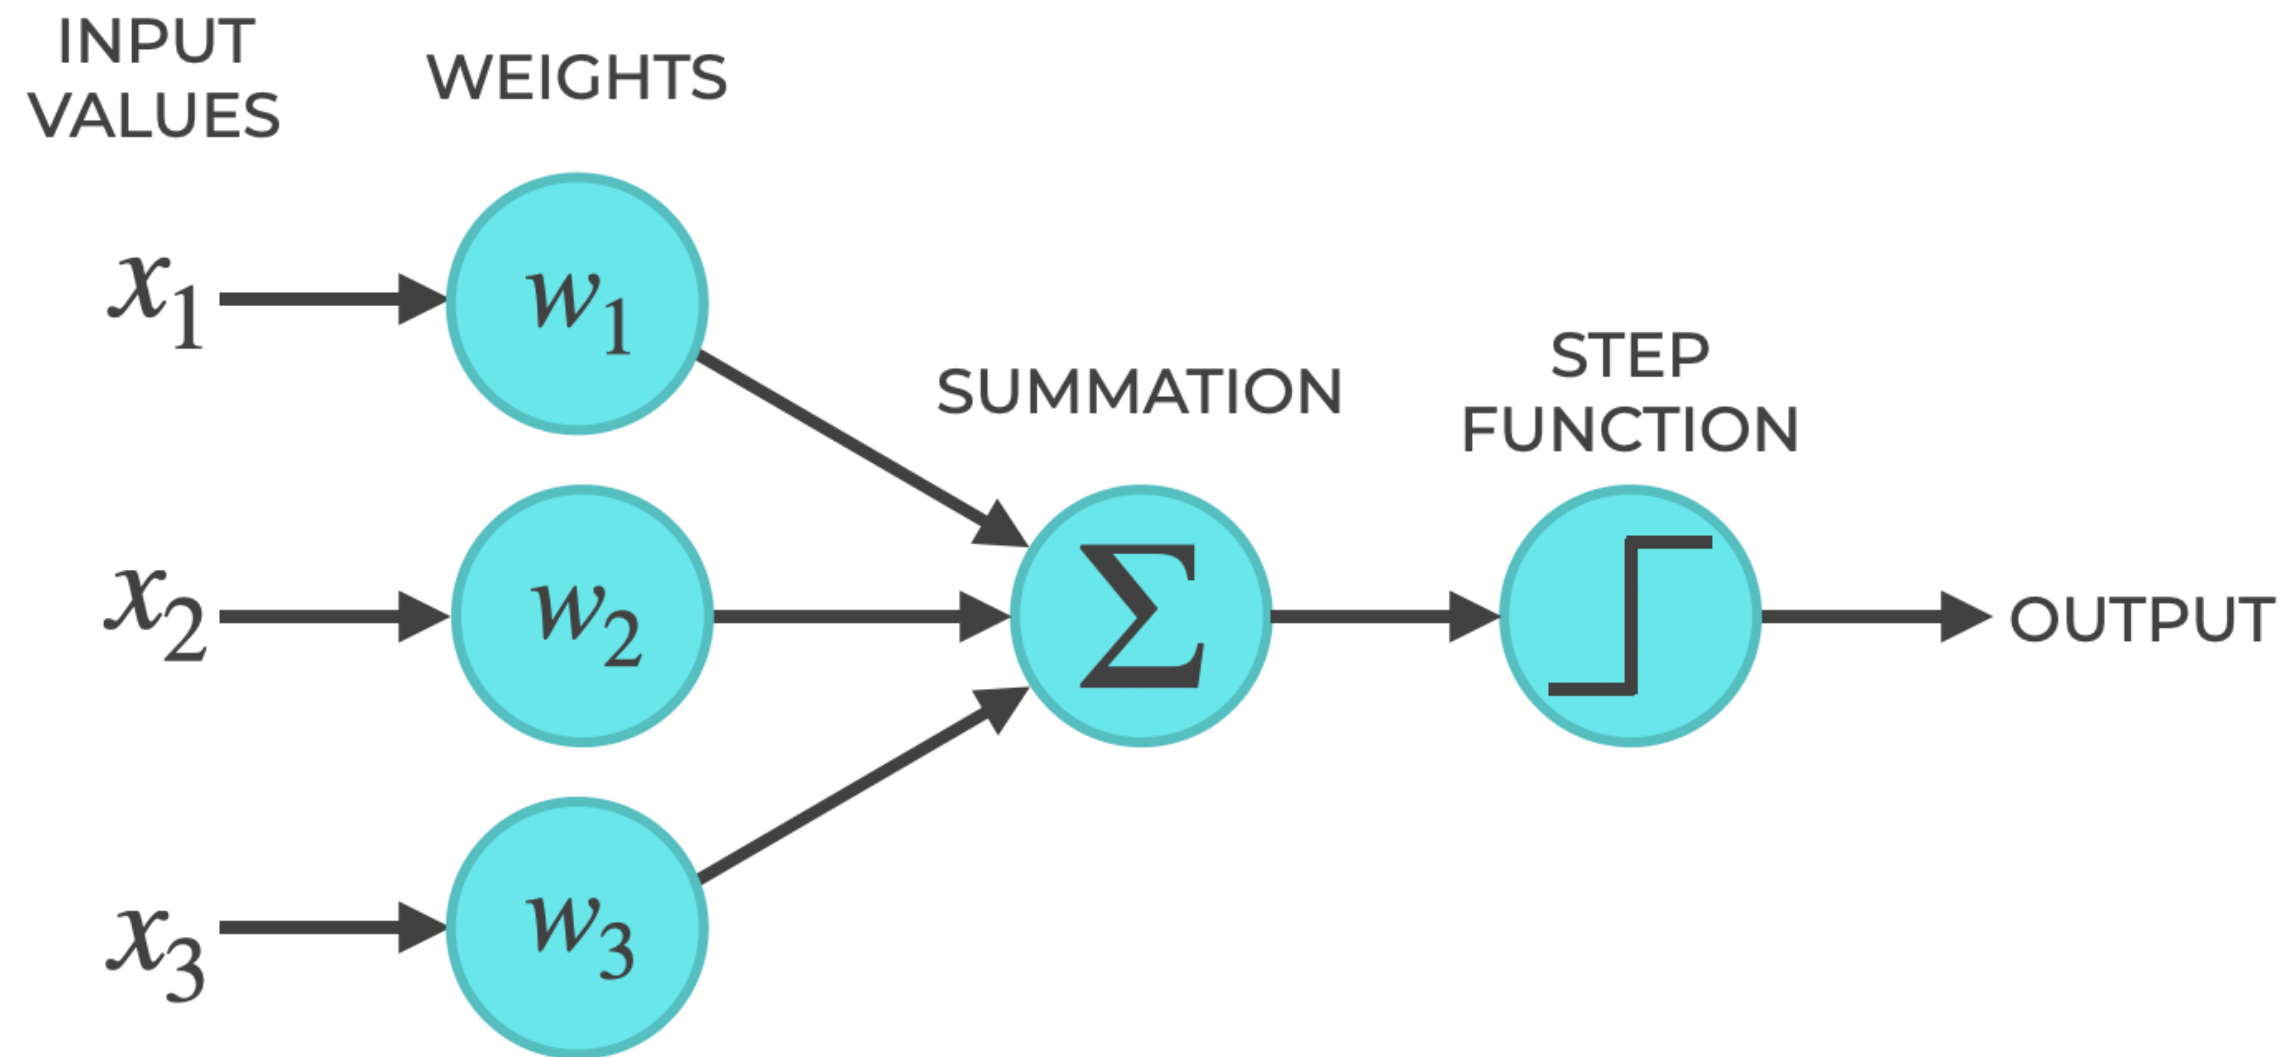
- Adequada para problemas de classificação binária (ativação sigmoid na saída).

- **Entropia Cruzada Categórica (CCE):**


$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c})$$

- Ideal para classificação multiclasse (ativação softmax na saída).

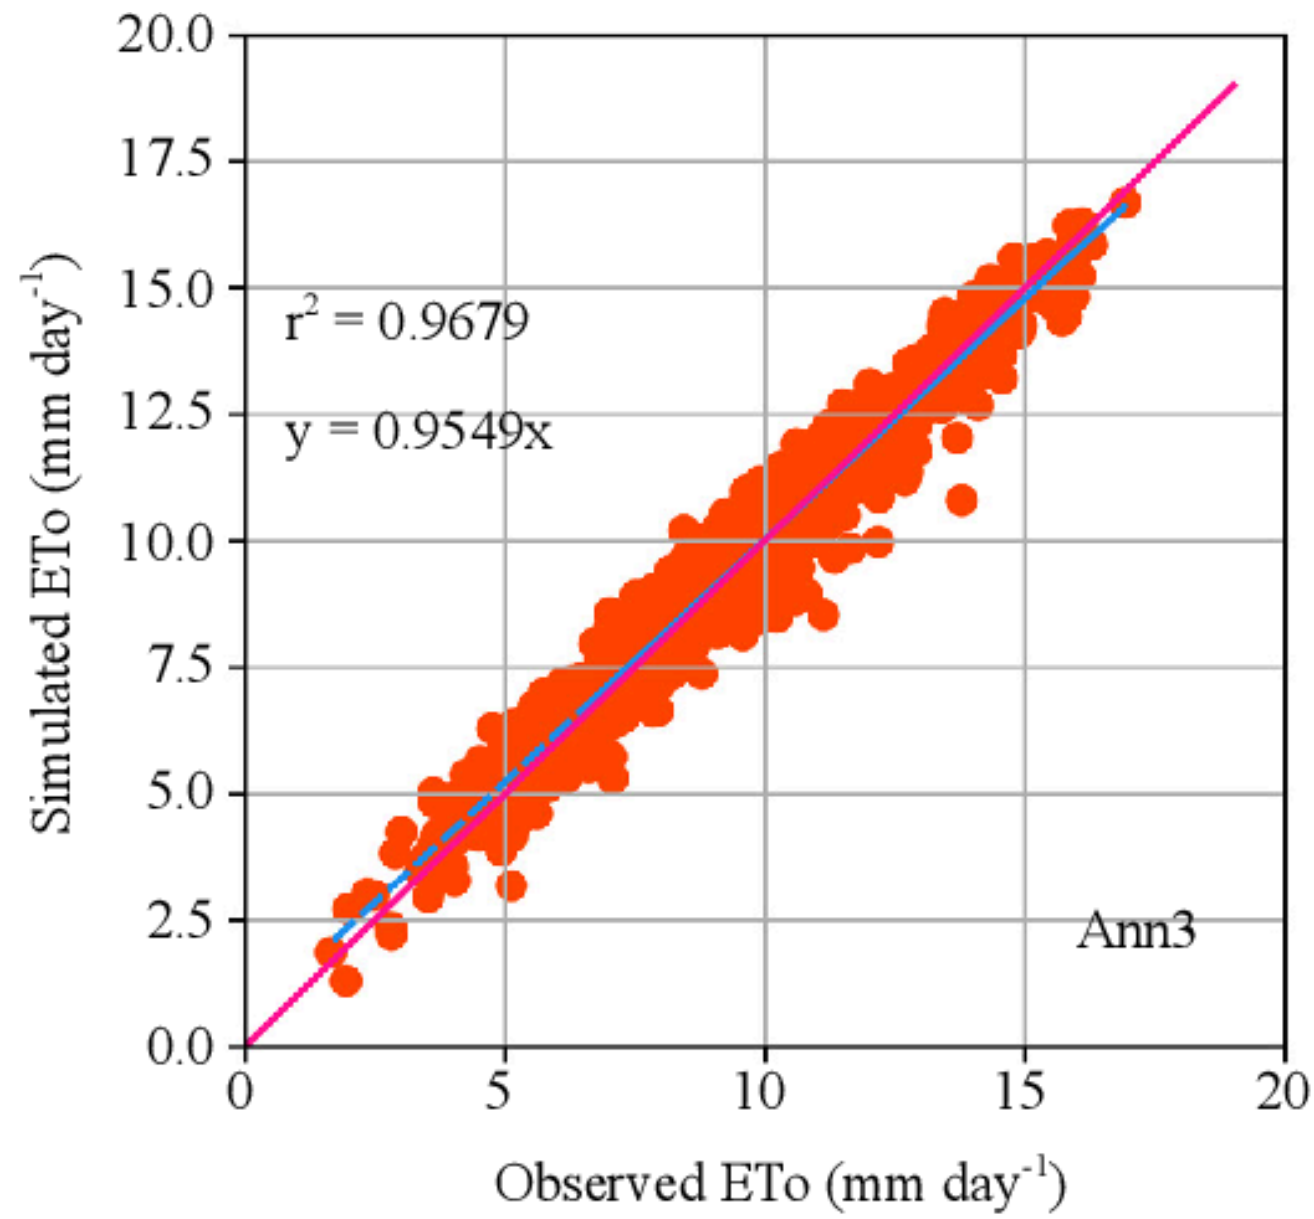
PERCEPTRON



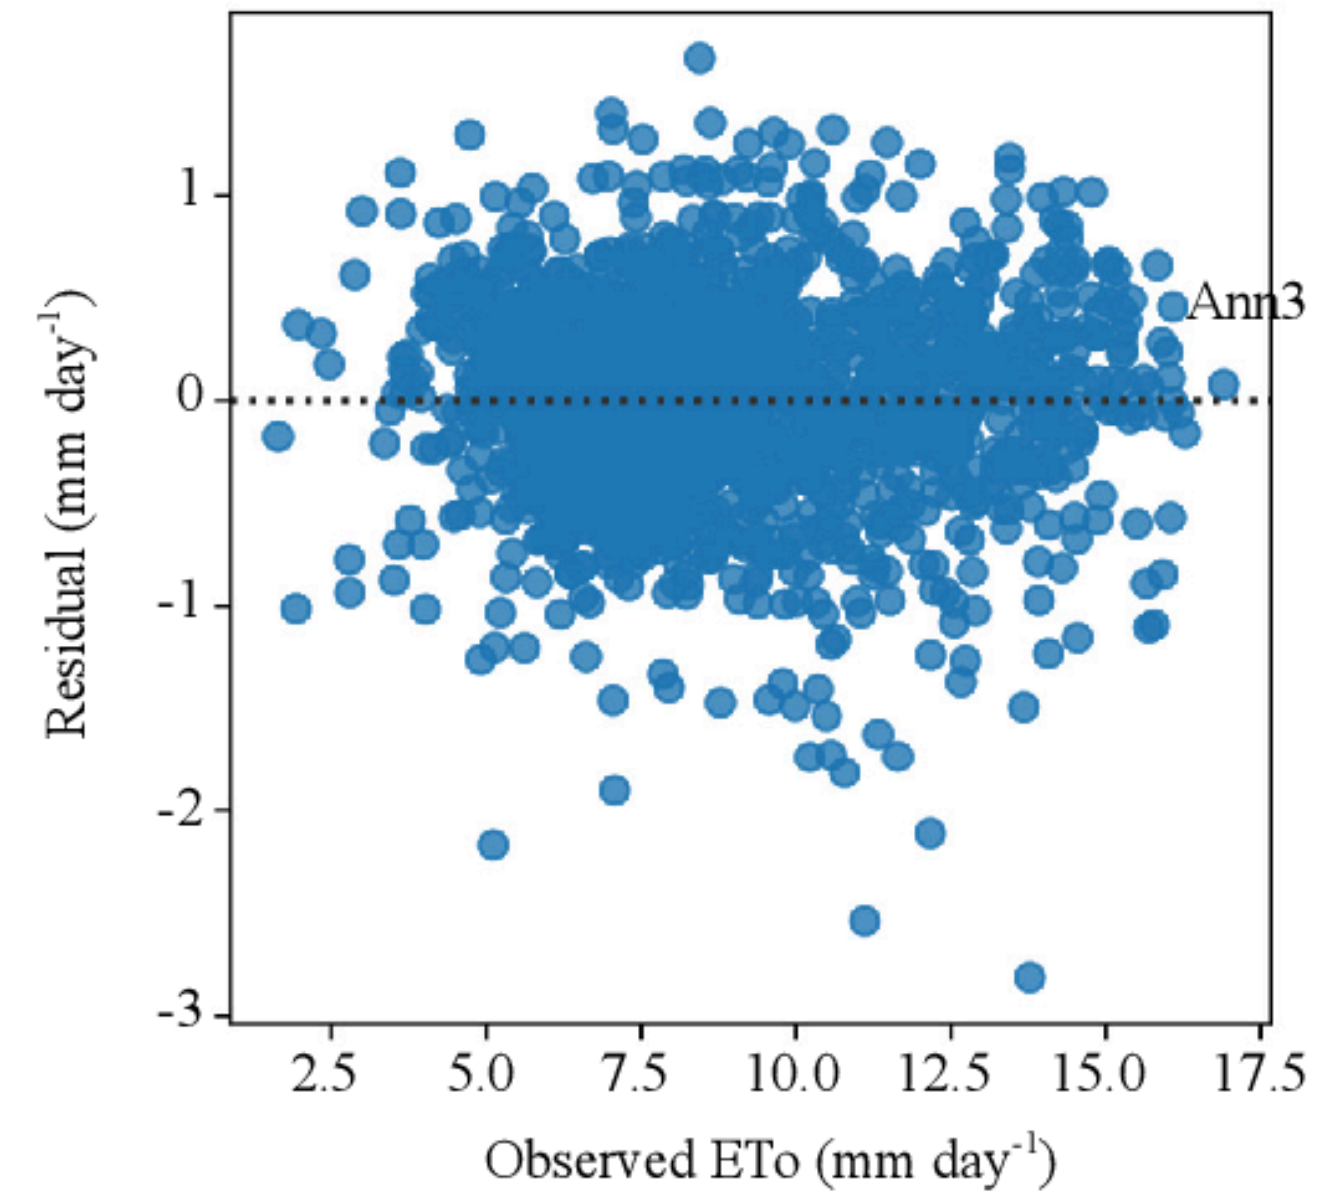
PERCEPTRON PARA CLASSIFICAÇÃO



PERCEPTRON PARA REGREÇA




(a)



(b)

LIMITAÇÕES DO PERCEPTRON





IMPLEMENTAÇÃO

**SIGA PARA IMPLEMENTAÇÕES DE EXEMPLOS
PRÁTICOS DO PERCEPTRON PRESENTES NESTE
REPOSITÓRIO**

OBRIGADO PELA ATENÇÃO!